



Aprenda com quem faz

# Mensuração e Estratégia em Renda Variável

Prof. Leandro Guerra

2023



## SUMÁRIO

Capítulo 1. Valuation e precificação .....	5
1.1. Intuição sobre ativo, precificação e valuation.....	5
1.2. Como o mercado de capitais funciona .....	10
1.3. Os 3 tipos de demonstrações financeiras .....	11
1.4. Relação entre as demonstrações e análise de negócios .....	16
Capítulo 2. Teoria de Markowitz e técnicas tradicionais de seleção de carteira.....	19
2.1. Aversão ao risco .....	19
2.2. Definição de carteira.....	20
2.4. Modern Portfolio Theory (MPT).....	24
Capítulo 3. O processo de mineração de dados ( <i>data mining</i> ) .....	27
3.1. O que é data mining?.....	27
3.2. O processo de extração de dados .....	28
3.3. Modelos (técnicas) de Data Mining.....	30
3.4. Etapas de Data Mining.....	31
Capítulo 4. Compreensão e definição do alvo de modelos de renda variável.....	36
4.1. Definição do alvo e sua importância .....	36
4.2. A importância da volatilidade para o alvo .....	38
4.3. Métodos para a escolha do alvo .....	40
4.4. Não é apenas sobre retornos.....	41
Capítulo 5. Algoritmos de aprendizado de máquina para trading .....	44
5.1. Long & Short por cointegração .....	44
5.2. Trading com Regressão Logística.....	46
5.3. Trading com Rede Neural .....	48

5.4. Previsão de volatilidade.....	49
Capítulo 6. Monitoramento e atualização de modelos de renda variável.....	52
6.1. O que é monitoramento .....	52
6.2. Quando substituir ou atualizar o modelo .....	54
Capítulo 7. Seleção de carteira utilizando algoritmos de aprendizado de máquina.....	58
7.1. Seleção pelo método do K-means .....	58
7.2. Literatura relevante.....	60
Capítulo 8. Métodos quantitativos para gestão de risco.....	63
8.1. O que é o VaR .....	63
8.2. O problema do VaR .....	64
8.3. Conditional Value at Risk (CVaR) .....	65
8.4. Critério de Kelly .....	67
Referências .....	69



**XP**e

# > Capítulo 1



## Capítulo 1. Valuation e precificação

---

### 1.1. Intuição sobre ativo, precificação e valuation

Um ativo é um recurso com valor econômico que um indivíduo, corporação ou país possui ou controla com a expectativa de fornecer um benefício futuro. Os ativos são relatados no balanço patrimonial de uma empresa, que veremos mais a frente nos tipos de demonstrações financeiras. Eles são comprados ou criados para aumentar o valor de uma empresa ou beneficiar as operações da empresa.

Um ativo pode ser pensado como algo que, no futuro, pode gerar fluxo de caixa, reduzir despesas ou melhorar as vendas, independentemente de ser um equipamento de fabricação, uma patente, propriedade intelectual ou mesmo um outro título financeiro.

Essa definição é fundamental desta porque ela automaticamente nos leva a algumas perguntas, por exemplo: como saber o preço ou valor de um ativo? O que é precificação? Como fazer a avaliação do preço?


#### Como saber o preço de um ativo? Precificação.

Vamos concentrar a nossa atenção no preço de uma ação, que é o tema principal dentro deste curso de renda variável. O termo preço das ações refere-se ao preço atual pelo qual uma ação está sendo negociada no mercado. Toda empresa de capital aberto, quando suas ações são emitidas, recebe um preço – uma atribuição de seu valor que reflita idealmente o valor da própria empresa. O preço de uma ação sobe e desce em relação a vários fatores diferentes, incluindo mudanças na economia como um todo, mudanças nas indústrias, eventos políticos, guerra e mudanças ambientais.

Se uma empresa produz um bem que poucas outras produzem ou um bem altamente desejado ou necessário, o preço de seu estoque subirá porque a demanda é alta. Quando a oferta do bem se equilibra com a

demanda, os preços das ações tendem a se estabilizar. Se a oferta for maior que a demanda, o preço das ações da empresa provavelmente cairá. No final, é realmente sobre a lei da oferta (*supply*) e da procura/demanda (*demand*). A figura 1 mostra o funcionamento dessa curva.

Figura 1 – Curvas de oferta e demanda.



Fonte: [Holistic Design Education to Promote Sustainable Systems.](#)

Para um determinado nível ou quantidade de bens ou serviços (eixo horizontal) existirá uma oferta associada (*supply*) e o momento em que essas curvas se encontram, aquele é o preço de equilíbrio, representado no eixo vertical.

E o preço que é oferecido no mercado é o ponto de equilíbrio entre esses dois. Porém, sabemos que esse preço pode variar – e muitas vezes varia muito. O que faz essa variação acontecer?

Um dos pontos mais relevantes é a avaliação que uma empresa e/ou suas ações podem receber dos demais agentes do mercado. E esta avaliação tem um nome e processo bem definidos: o *valuation*, do seu termo em inglês.

## O que é valuation?

Saber quanto vale um ativo e o que determina esse valor é um pré-requisito para uma tomada de decisão inteligente – na escolha de investimentos para um portfólio, na decisão sobre o preço adequado a pagar ou receber em uma aquisição e na realização de investimentos, financiamentos e dividendos. A premissa da avaliação (*valuation*) é que podemos fazer estimativas razoáveis de valor para a maioria dos ativos e que os mesmos princípios fundamentais determinam os valores de todos os tipos de ativos, tanto reais quanto financeiros. Alguns ativos são mais fáceis de avaliar do que outros, os detalhes da avaliação variam de ativo para ativo e a incerteza associada às estimativas de valor é diferente para diferentes ativos, mas os princípios básicos permanecem os mesmos.

Os investidores usam métricas financeiras constantemente para determinar o valor da empresa, incluindo seu histórico de ganhos, mudanças no mercado e o lucro que pode ser razoavelmente esperado. Isso fará com que os investidores estimem os preços das ações para cima e para baixo. E a aplicação básica é conhecida: investidores visam obter um retorno sobre seus investimentos. É feito de duas maneiras elementares:

- Dividendos – Se as ações da empresa pagam dividendos, pagamentos regulares são feitos aos acionistas para cada ação detida;
- Comprar ações quando elas estão a um preço baixo e vendê-las de volta quando o preço sobe.

Existem duas visões extremas do processo de *valuation*. De um lado estão aqueles que acreditam que, feita corretamente, é uma ciência difícil, onde há pouco espaço para opiniões de analistas ou erro humano. Do outro estão aqueles que sentem que o processo de *valuation* é mais uma arte, onde analistas experientes podem manipular os números para gerar o resultado que quiserem. A verdade está em algum lugar no meio disto, dado

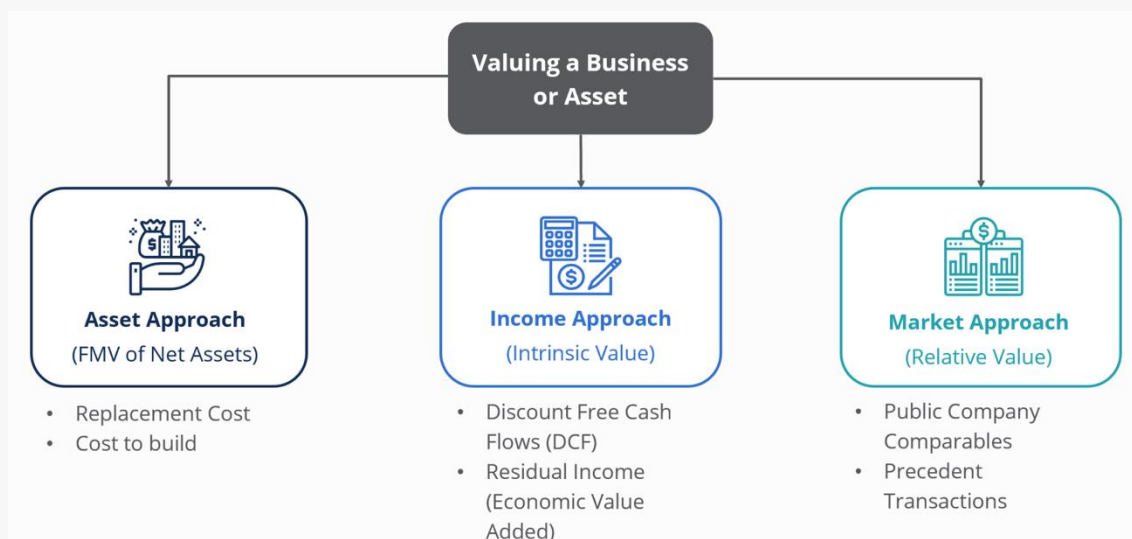
quem sempre existe o viés que os analistas trazem para o processo, a incerteza com a qual precisam lidar e a complexidade que a tecnologia moderna e o fácil acesso à informação trouxeram à avaliação.

Ao avaliar uma empresa em continuidade, existem três métodos principais de avaliação usados pelos profissionais da indústria:

- Análise do fluxo de caixa descontado;
- Análise de empresa de modo relativo; e
- Transações precedentes.

Segundo o *Corporate Finance Institute* (CFI), esses são os métodos mais comuns de avaliação usados em bancos de investimento e na maioria das áreas de finanças. A figura 2 mostra um resumo importante dos 3 métodos.

**Figura 2 – Resumo dos principais métodos de valuation.**



**Fonte: Corporate Finance Institute.**

Não é o objetivo deste curso adentrar nos detalhes dos 3 métodos. Porém, saber que eles existem e posterior aprofundamento é fundamental



para duas partes principais do processo de modelagem e das estratégias quantitativas: definição do alvo e a criação de variáveis.

Também, de um modo geral, o papel que o *valuation* desempenha na gestão de carteiras é determinado em grande parte pela filosofia de investimento do investidor. Ele desempenha um papel mínimo na gestão de portfólio para um investidor passivo, enquanto desempenha um papel maior para um investidor ativo. Mesmo entre investidores ativos, a natureza e o papel da avaliação são diferentes para diferentes tipos de investimento ativo. Entre os selecionadores de títulos, a avaliação desempenha um papel central na gestão de portfólio para analistas fundamentais e um papel periférico para analistas técnicos.

No caso dos Analistas fundamentalistas, o verdadeiro valor da empresa pode estar relacionado às suas características financeiras – suas perspectivas de crescimento, perfil de risco e fluxos de caixa. Qualquer desvio desse valor real é um sinal de que uma ação está sub ou supervalorizada. É uma estratégia de investimento de longo prazo, e os pressupostos subjacentes são que:

- A relação entre o valor e os fatores financeiros subjacentes pode ser medida.
- A relação é estável ao longo do tempo.
- Desvios do relacionamento são corrigidos em um período razoável.

Os analistas fundamentalistas incluem investidores de valor e de crescimento. A principal diferença entre os dois está em onde está o foco da avaliação. Os investidores de valor estão principalmente interessados em ativos existentes e em adquiri-los por um valor inferior ao seu valor real. Os investidores em crescimento, por outro lado, estão muito mais focados em avaliar ativos de crescimento e comprar esses ativos com desconto. Embora o *valuation* seja o foco central da análise fundamentalista, alguns analistas

usam modelos de fluxo de caixa descontado para avaliar empresas, enquanto outros usam múltiplos e empresas comparáveis, como vimos acima. Uma vez que os investidores que utilizam essa abordagem e possuem muitas ações subvalorizadas em suas carteiras, sua esperança é que, em média, essas carteiras se saiam melhor do que o mercado.

Para que o isso seja possível, devemos entender um pouco mais sobre as demonstrações financeiras, que são a matéria prima para o processo de *valuation*. Mas antes, precisamos também entender como o mercado de capitais funciona.

## 1.2. Como o mercado de capitais funciona

Antes que o aluno pense que essa é uma pergunta elementar demais, em todos estes anos como professor ainda percebo que profissionais experientes não tem este conceito definido claramente. Então é preciso preencher essa lacuna. Na figura 3 temos um resumo muito preciso deste processo.

**Figura 3 – Como o mercado de capitais funciona.**



**Fonte: Adaptação do autor da referência Equity Asset Valuation Workbook.**

Os mercados de capitais são mercados financeiros que reúnem compradores e vendedores para negociar ações, títulos, moedas e outros ativos financeiros. Os mercados de capitais incluem o mercado de ações e o mercado de títulos. Os investidores compram esses ativos e, no caso de

ações, obtêm propriedade parcial de uma empresa e a oportunidade de obter retornos sobre seus investimentos.

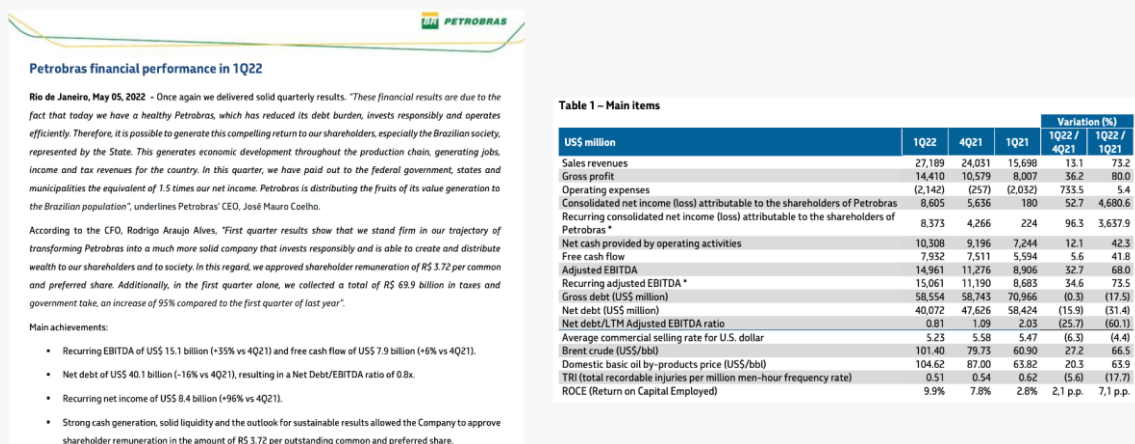
Os mercados de capitais existem em formas primárias e secundárias. O mercado primário é onde o título (ação ou título) é originalmente emitido para levantar o capital. Após essa emissão, o título é negociado em um mercado secundário (provavelmente é o que você costuma chamar de mercado de ações). Se você comprar o título no mercado secundário, ainda receberá pagamentos emitidos pela empresa. Isso significa que os pagamentos de principal e juros sobre títulos e pagamentos de dividendos sobre ações chegariam à sua conta.

Os outros mercados de capitais comumente usados são os mercados de câmbio e derivativos. As empresas usam os mercados de câmbio para proteger os riscos incorridos pela geração de receita nos mercados estrangeiros e os comerciantes usam-no para aproveitar as diferenças nas taxas de juros com o “carry trade”. Um derivativo comum para investidores individuais e empresas é o mercado futuro, onde as empresas podem fixar o preço de uma commodity a ser entregue no futuro, assim como também o mercado de opções de ações.

### 1.3. Os 3 tipos de demonstrações financeiras

Começamos entendendo para o quê serve estudar uma demonstração financeira. Ela serve para entender pontos como o da figura 4 a seguir.

Figura 4 – Demonstração de resultados da Petrobras.



Fonte: Relações com Investidores Petrobras.

E para entendê-las também é preciso algumas noções de contabilidade, disciplina essa que é repleta de mitos, como:

- Contabilidade é matemática e não sou bom com matemática;
- A contabilidade deve ser deixada para os contadores;
- Eu não consigo entender todos esses jargões;
- A contabilidade é chata.

O que é um grande engano. As demonstrações financeiras são uma importante fonte de informação para os mercados de capitais e analistas de negócios. A análise das demonstrações financeiras aborda uma série de questões de interesse para as partes interessadas externas e os membros da empresa e é um item fundamental para a tomada de decisão interna e externa.

- Interna: decisões de natureza operacional ou de investimentos;
- Externa: atender investidores, reguladores e o mercado em geral.

A aplicação dos princípios contábeis é responsabilidade da administração da empresa, que possui conhecimento superior dos negócios

de si mesma. Existem incentivos para que a administração distorça os números contábeis a seu favor.

- Contratos;
- Bônus;
- Valor da ação;
- Reputação.

Efeitos atenuantes de possíveis distorções: responsabilidade legal, auditoria, execução pública.

As demonstrações financeiras medem e resumem as consequências econômicas das atividades empresariais. Os sistemas de contabilidade facilitam a qualidade da informação:

- O papel da contabilidade de competência (*accrual accounting*).
- A necessidade de convenções e normas contábeis.
- Escolhas e estratégias contábeis dos gerentes.
- Auditoria e qualidade da informação financeira.

E quais são as 3 principais demonstrações financeiras?

- Declaração de renda/receita (*Income Statement*).
- Demonstração da Posição Financeira ou DRE (Demonstrativo de Resultado do Exercício ou *Statement of Financial Position* ou *Balance Sheet*).
- Fluxo de caixa (*Cash Flow*).

Na figura 5 temos um exemplo de onde todas essas 3 demonstrações podem ser encontradas.

**Figura 5 – As três demonstrações financeiras.**

**Petróleo Brasileiro S.A. - Petrobras (PBR)** [Add to watchlist](#)

NYSE - NYSE Delayed Price. Currency in USD

**11.64** **+0.17 (+1.48%)** **11.64** **0.00 (0.00%)**

At close: July 22 04:00PM EDT After hours: 07:58PM EDT

Advertisement

[Summary](#) [Chart](#) [Conversations](#) [Statistics](#) [Historical Data](#) [Profile](#) **[Financials](#)** [Analysis](#) [Options](#) [Holders](#) [Sustainability](#)

Show: **Income Statement** [Balance Sheet](#) [Cash Flow](#) Annual [Quarterly](#)

**Income Statement** Currency in BRL. All numbers in thousands [Expand All](#)

Breakdown	TTM	12/30/2021	12/30/2020	12/30/2019	12/30/2018
> Total Revenue	95,457,000	83,966,000	53,683,000	76,589,000	95,584,000
Cost of Revenue	48,252,000	43,164,000	29,195,000	45,732,000	61,517,000
Gross Profit	47,205,000	40,802,000	24,488,000	30,857,000	34,067,000
> Operating Expense	8,074,000	7,868,000	7,976,000	12,355,000	10,487,000
Operating Income	39,131,000	32,934,000	16,512,000	18,502,000	23,580,000
> Net Non Operating Interest Inc...	-4,187,000	-4,644,000	-5,655,000	-6,314,000	-2,636,000
> Other Income Expense	5,976,000	-65,000	-11,083,000	-185,000	-8,846,000
Pretax Income	40,920,000	28,225,000	-226,000	12,003,000	12,098,000
Tax Provision	12,486,000	8,239,000	-1,174,000	4,200,000	4,684,000

**Fonte: Yahoo Finance.**

A DRE captura a posição da empresa em um momento no tempo. Ela torna públicos os resultados das operações de negócios de uma empresa para um determinado trimestre ou ano. Por meio da demonstração de resultados, você pode verificar a entrada de novos ativos em uma empresa e medir as saídas incorridas para produzir receita. A lucratividade é medida pelas receitas (o que uma empresa recebe pelos bens ou serviços que fornece) menos despesas (todos os custos incorridos para administrar a empresa) e impostos pagos.

A demonstração de resultados é lida de cima para baixo, começando com as receitas, às vezes chamadas de "linha superior". Despesas e custos são subtraídos, seguidos de impostos. O resultado é o lucro líquido da

empresa – ou lucro – antes de pagar quaisquer dividendos, e é daí que vem o termo "resultado final".

Enquanto a demonstração de resultados é um registro dos fundos que entram e saem de uma empresa em um determinado período, o balanço patrimonial consolidado é um instantâneo da posição financeira de uma empresa em um determinado momento. Em outras palavras, o balanço patrimonial mostra o que uma empresa possui (ativo) e deve (passivo) e a diferença entre os dois (patrimônio líquido). Essa diferença representa o valor contábil da participação dos acionistas na empresa. É chamado de balanço patrimonial porque ambos os lados da equação devem se equilibrar: ativos iguais a passivos mais patrimônio líquido.

Por fim, mas não menos importante, a demonstração do fluxo de caixa reflete a atividade financeira de uma empresa durante um período. Mostra de onde vem o caixa da empresa e como ele é usado para pagar as operações e/ou investir no futuro. Ao mostrar como uma empresa administrou as entradas e saídas de caixa, a demonstração dos fluxos de caixa pode apresentar um quadro mais completo da liquidez de uma empresa (a capacidade de pagar contas e credores e financiar o crescimento futuro) do que a demonstração de resultados ou o balanço patrimonial.

O preço das ações de uma determinada empresa pode aumentar ou diminuir com base em uma ampla variedade de fatores. No entanto, as empresas com bom desempenho financeiro, aumentando seus ganhos, patrimônio líquido e fluxo de caixa, geralmente são recompensadas com um preço mais alto das ações ao longo do tempo. Quando se trata de trading, conhecimento é poder. Mesmo os traders que geralmente dependem de fatores técnicos para tomar suas decisões de negociação podem se beneficiar ao aprender a usar demonstrações financeiras padrão para aprimorar as empresas que estão passando por fundamentos fortes ou melhorando.

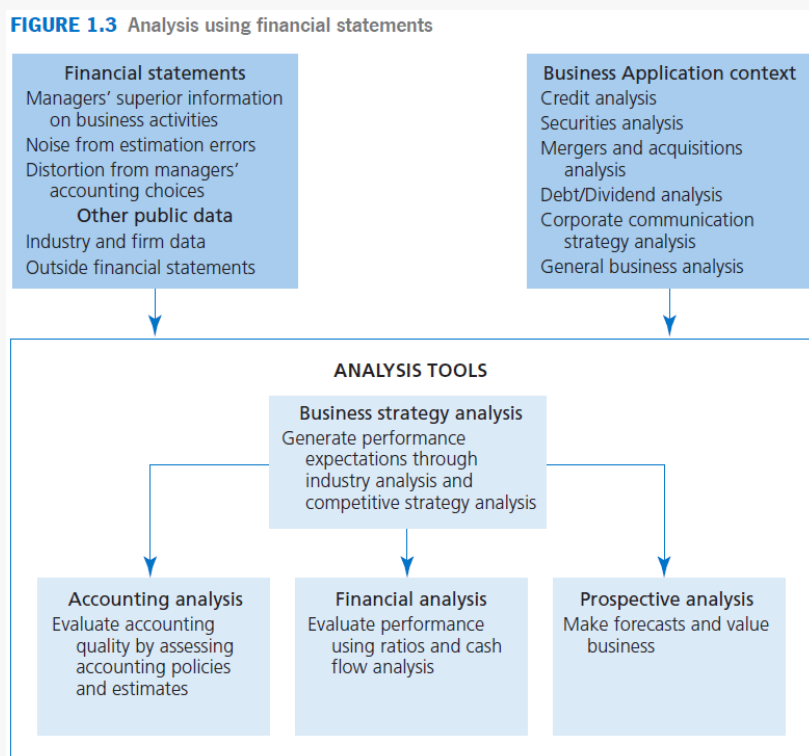
## 1.4. Relação entre as demonstrações e análise de negócios

Os analistas usam as demonstrações financeiras para atingir quatro objetivos principais:

- Análise de estratégia de negócios;
- Análise contábil;
- Análise financeira;
- Análise prospectiva.

Por isso eles precisam entender a relação das demonstrações com o negócio.

**Figura 6 – Relação entre as demonstrações e análise de negócios.**



**Fonte:** Adaptação do autor da referência *Equity Asset Valuation Workbook*.

As demonstrações financeiras não são itens isolados, elas estão intimamente relacionadas e fluem entre si para dar uma visão mais ampla



das circunstâncias financeiras do negócio. Cada instrução pode ser independente para oferecer um instantâneo, uma fotografia das informações fornecidas. Mas separadamente, não permitem uma visão aprofundada de toda a situação financeira da empresa.

A análise das demonstrações financeiras é crucial para o cumprimento das leis e regulamentos comerciais, ao mesmo tempo em que atende às necessidades das partes interessadas e de várias outras partes. Mas, para conduzir uma análise precisa das demonstrações financeiras, desenvolver habilidades e intuição é tão importante quanto seguir as melhores práticas contábeis.

A análise de demonstrações financeiras pode beneficiar as organizações de várias maneiras. Ele fornece às partes interessadas internas e externas a oportunidade de tomar decisões informadas sobre investimentos. A análise das demonstrações financeiras também fornece às instituições de crédito uma visão imparcial da saúde financeira de uma empresa, o que é útil para tomar decisões de empréstimo. E como os altos executivos e outros na administração confiam na contabilidade para fornecer uma descrição precisa dos efeitos de suas decisões, a análise das demonstrações financeiras também ajuda nas questões de governança corporativa.

O crescimento dos negócios depende da análise precisa e oportuna das demonstrações financeiras. Embora o ritmo acelerado dos negócios hoje dê mais importância aos insights coletados pelos contadores, o desenvolvimento do conhecimento ainda é um aspecto essencial do crescimento de um negócio. Para profissionais interessados em uma carreira que pode causar um impacto significativo em empresas, investidores e consumidores, fazer um mestrado em contabilidade pode ser um empreendimento especialmente valioso.



**XP**e

## > Capítulo 2



## Capítulo 2. Teoria de Markowitz e técnicas tradicionais de seleção de carteira

---

### 2.1. Aversão ao risco

Um dos aspectos mais importantes para a análise de ações é analisar seus modelos de risco e como avaliar o ativo. O risco financeiro deve ser entendido como o risco dos mercados financeiros com base no risco de liquidez, operacional e estratégico. A aversão ao risco é um dos pilares das teorias utilizadas pelos economistas. A teoria da escolha do investidor analisa o comportamento dos indivíduos quando confrontados com a tarefa de classificar alternativas arriscadas e a suposição de não saciedade. Markowitz (1952) considera que um investidor é avesso ao risco quando recebe mais utilidade do valor atuarial de uma aposta obtida com certeza do que da própria aposta. Markowitz também considera a atitude de risco no processo de seleção de carteiras, implementando a teoria dos jogos e comportamento econômico descrita por Von Neumann e Morgenstern (1944).

As preferências de risco dependem de muitos determinantes; mas, para facilitar sua implementação, a literatura clássica os resume por um único coeficiente de aversão ao risco. O uso de aprendizado de máquina nos mercados financeiros permite o processamento cada vez mais rápido de dados em muitas variáveis macro e financeiras. Essas informações de melhor qualidade fornecem informações sobre as expectativas dos investidores modernos e reduzem suas incertezas sobre os resultados dos investimentos. Nesse contexto, o objetivo desta seção é entender sobre aversão ao risco comparando a natureza invariante e dinâmica das preferências de risco.

Falando de forma mais prática, a aversão ao risco é um conceito importante para os investidores. Investidores extremamente avessos ao

risco preferem investimentos que ofereçam um retorno garantido, ou “sem risco”. Eles preferem isso mesmo que o retorno seja relativamente baixo em comparação com retornos potencialmente mais altos que carregam um grau mais alto de risco. Por exemplo, investidores extremamente avessos ao risco preferem investimentos como títulos do governo e certificados de depósito bancários (CDBs) a investimentos de maior risco, como ações e commodities.

Investidores com maior tolerância ao risco – ou níveis mais baixos de aversão ao risco – estão dispostos a aceitar maiores níveis de risco em troca da oportunidade de obter maiores retornos sobre o investimento.

## 2.2. Definição de carteira

Uma carteira ou portfólio é uma coleção de uma ampla gama de ativos pertencentes a investidores. A referida coleção de ativos financeiros também pode ser valores que variam de ouro, fundos de ações, derivativos, propriedades, equivalentes a caixa, títulos etc.

Dependendo do conhecimento do mercado de investimentos, os investidores podem gerenciar seu portfólio ou buscar a ajuda de consultores financeiros profissionais. De acordo com especialistas financeiros, a diversificação é um conceito vital na gestão de portfólio. Os dois principais tipos de ativos financeiros são ações e títulos públicos.

Embora existam vários tipos de carteiras de investimento, os investidores fazem questão de construir uma que corresponda à sua intenção de investimento e capacidade de risco. Com base em estratégias de investimento, estes são alguns tipos comuns de carteiras:

- **Renda:** Este tipo de carteira enfatiza mais a garantia de um fluxo constante de renda de avenidas de investimento. Em outras palavras, não é totalmente focado no potencial de valorização do capital.

- Por exemplo, os investidores orientados para a renda podem investir em ações que geram dividendos regulares, em vez daquelas que mostram uma faixa de valorização do preço.
- **Crescimento (*Growth Stocks*):** Um portfólio orientado para o crescimento geralmente investe dinheiro em ações de crescimento de uma empresa que está em seu estágio de crescimento ativo. Normalmente, as carteiras de crescimento estão sujeitas a riscos maiores. Esse tipo de carteira é conhecido por apresentar altos aspectos de risco e recompensa.
- **Valor (*Value*):** Este portfólio coloca dinheiro em ativos baratos na avaliação e se concentra em garantir barganhas no mercado de investimentos. Quando a economia está em dificuldades e as empresas mal conseguem sobreviver, os investidores orientados para o valor procuram empresas lucrativas cujas ações tenham um preço inferior ao seu valor justo. Quando o mercado se recupera, os detentores de carteiras de valor geram ganhos substanciais. Os investidores devem observar que vários fatores tendem a influenciar a forma como alguém decide construir um portfólio.

Com a ajuda de uma boa gestão de portfólio, os investidores podem construir o melhor plano de investimento que corresponda aos seus rendimentos, objetivos financeiros, idade e capacidade de risco. Esses indicadores abaixo destacam a necessidade subjacente de gerenciamento ativo de portfólio:

- Ajuda a amortecer os riscos do investimento e aumenta o escopo de gerar mais lucros;
- Ajuda a desenvolver estratégias sólidas e reequilibrar a composição de ativos de acordo com sua condição atual de mercado, para que os investidores possam aproveitar ao máximo o investimento existente;

- Permite customização rápida com base em necessidades financeiras imediatas e condições de mercado;
- Ajuda a entender quais investimentos funcionam melhor em qual situação de mercado e como distribuir recursos em diferentes classes de ativos.

A melhor maneira de construir uma carteira de investimentos sólida é determinar seu objetivo financeiro e reequilibrar seus componentes com frequência. Posteriormente, os investidores devem se concentrar mais na diversificação de seus recursos para obter as melhores recompensas possíveis em riscos gerenciáveis em todas as situações. Caso os indivíduos não tenham visão de futuro ou conhecimento de mercado para administrar um portfólio, eles devem buscar uma opinião profissional. E esse será o papel do cientista de dados na formação e gestão de carteira.

E como fazer isso? Um dos meios possíveis será discutido nas próximas seções.

### 2.3. O modelo CPAM

Grande parte da literatura financeira dedica discussões exclusivas ao Modelo de Precificação de Ativos de Capital (CAPM).

No modelo CAPM, a relação entre risco e taxas de retorno em um título é descrita na equação 1:


$$R_i = R_f + \beta_i(E[R_{mkt}] - R_f) \quad (1)$$

Onde para um título  $i$ , seus retornos são definidos como  $R_i$  e seu beta como  $\beta_i$ . O CAPM define o retorno do título como a soma da taxa livre de risco,  $R_f$ , e a multiplicação de seu beta pelo prêmio de risco. O prêmio de risco pode ser pensado como os retornos excedentes da carteira de mercado, excluindo a taxa livre de risco. Como podemos ver, ele nada mais é do que uma regressão linear tendo a taxa livre de risco e o risco do ativo

como principais elementos para determinar o retorno de um ativo ou grupo de ativos.

Na figura 7 temos a representação gráfica do CAPM.

**Figura 7 – Representação gráfica do CAPM.**



**Fonte:** [Relationship between Risk and Common Stock Return in CML and CAPM.](#)

Beta é uma medida do risco sistemático de uma ação – um risco que não pode ser afastado por diversificação. Em essência, descreve a sensibilidade dos retornos das ações em relação aos movimentos do mercado. Por exemplo, uma ação com um beta igual a zero não produz retornos excessivos, independentemente da direção em que o mercado se move. Ela só pode crescer a uma taxa livre de risco. Uma ação com um beta de 1 indica que a ação se move perfeitamente com o mercado. O beta é derivado matematicamente dividindo a covariância dos retornos entre a ação e o mercado pela variância dos retornos do mercado.

O modelo CAPM mede a relação entre risco e retorno de ações para cada ação na cesta de portfólio. Ao delinear a soma dessa relação, obtemos combinações ou pesos de títulos arriscados que produzem o menor risco de carteira para cada nível de retorno da carteira. Um investidor que deseja

receber um retorno específico possuiria uma dessas combinações de um portfólio ótimo que fornecesse o menor risco possível. As combinações de carteiras ótimas encontram-se ao longo de uma linha chamada de fronteira eficiente. Ao longo da fronteira eficiente existe um ponto tangente que denota o melhor portfólio ótimo disponível e dá a maior taxa de retorno em troca do menor risco possível. Essa carteira ótima no ponto tangente é conhecida como carteira de mercado.

Existe uma linha reta traçada da carteira de mercado até a taxa livre de risco. Essa linha é chamada de Linha de Mercado de Capitais (CML). O CML pode ser pensado como o índice de Sharpe mais alto disponível entre todos os outros índices de Sharpe de portfólios ótimos. O índice de Sharpe é uma medida de desempenho ajustada ao risco definida como os retornos excedentes da carteira sobre a taxa livre de risco por unidade de seu risco em desvios padrão. Os investidores estão particularmente interessados em manter combinações de ativos ao longo da linha CML. Ativos acima da linha estão subvalorizados e ativos abaixo da CML estão supervalorizados.

#### 2.4. Modern Portfolio Theory (MPT)

A teoria moderna do portfólio (MPT) é uma estratégia de investimento que minimiza o risco de mercado e maximiza os retornos. Baseia-se na premissa de que os mercados são eficientes e utiliza a diversificação para distribuir os investimentos em diferentes ativos. Ela também é conhecida como Análise de média-variância.

Desenvolvida pelo Prêmio Nobel Harry Markowitz, é um modelo amplamente utilizado. O MPT geralmente promove uma estratégia de comprar e manter com re-balanceamento ocasional.

Sabemos que investir em ações de crescimento pode acarretar um maior risco de perda quando comparado ao mercado em geral. Como resultado, uma carteira pode ter uma parcela alocada em títulos. Se o mercado de ações e as ações de crescimento caírem, os investimentos em



títulos ainda renderiam juros e experimentariam menos volatilidade, compensando, em parte, o risco de mercado da parcela de ações da carteira.

Outro exemplo envolve o investimento em ativos cujos preços são negativamente correlacionados, ou seja, seus preços tendem a se mover na direção oposta.

O MPT presume que o investidor pode manter um determinado tipo de ativo ou investimento de alto risco, mas quando ele o combina com outros de tipos diferentes, todo o portfólio pode ser equilibrado. Então seu risco é menor do que o risco individual dos ativos ou investimentos subjacentes. Por exemplo, o investidor não teria apenas ações de risco ou apenas títulos de baixo retorno. Em vez disso, ele compraria e manteria uma mistura de ambos para garantir o maior retorno possível ao longo do tempo.

A maneira mais simples de criar um portfólio eficiente é por meio de uma abordagem estratégica ou passiva. É aqui que o investidor compra e mantém combinações de ativos e investimentos que não são correlacionados positivamente. Em outras palavras, eles não sobem e descem nas mesmas condições de mercado. O investidor os inclui em seu portfólio em porcentagens fixas. Por exemplo, como uma classe de ativos, as ações geralmente têm maior risco de mercado do que os títulos. Uma carteira que consiste em ações e títulos pode obter um retorno razoável para um nível de risco relativamente menor.

Em nível de pessoa física, entretanto, isso pode ser bastante complicado. Por isso existe o Teorema dos Dois Fundos. O investidor não precisa de uma carteira complexa composta por muitos investimentos para estar em conformidade com o MPT. A teoria afirma que ele pode obter um portfólio eficiente com apenas dois fundos mútuos.

Toda a parte de equações e fórmulas serão abordadas nas aulas práticas com Python.



**XP**e

## > Capítulo 3

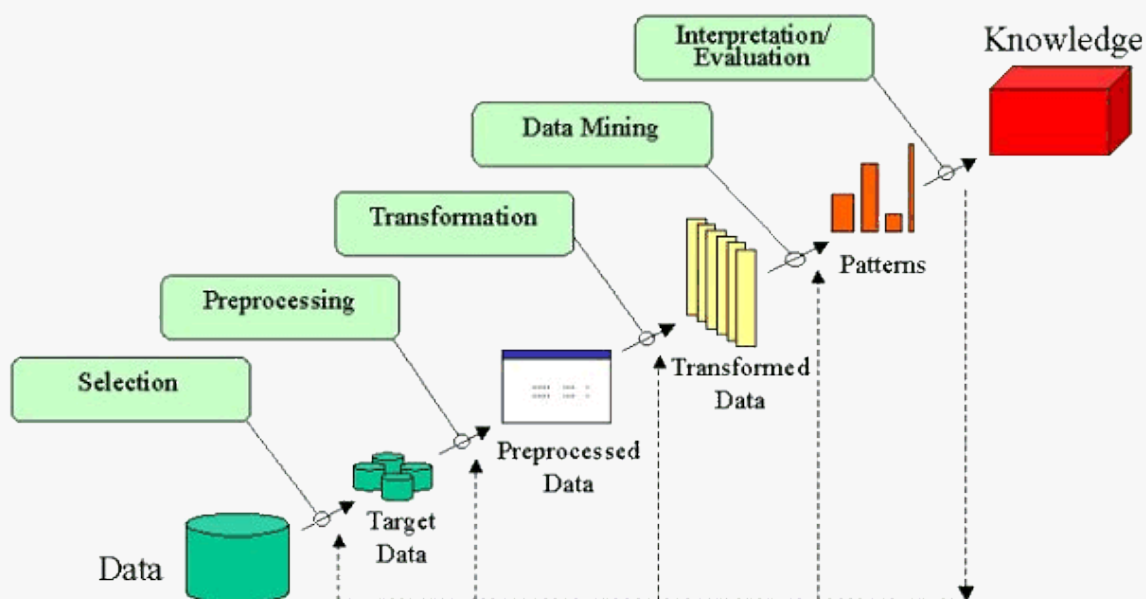


## Capítulo 3. O processo de mineração de dados (*data mining*)

### 3.1. O que é data mining?

A mineração de dados, também conhecida como descoberta de conhecimento em dados (KDD, descrito na figura 8), é o processo de descoberta de padrões e outras informações valiosas de grandes conjuntos de dados. Dada a evolução da tecnologia de armazenamento de dados e o crescimento do aprendizado de máquina, a adoção de técnicas de mineração de dados acelerou rapidamente nas últimas duas décadas, ajudando as empresas a transformar seus dados brutos em conhecimento útil. No entanto, ainda existem inúmeros desafios de escalabilidade e automação.

Figura 8 – Descoberta de conhecimento em dados (KDD).



Fonte: *Advances in Knowledge Discovery and Data Mining*, AAAI Press.

A mineração de dados melhorou a tomada de decisões organizacionais por meio de análises de dados. As técnicas de mineração de dados que sustentam essas análises podem ser divididas em dois propósitos principais; eles podem descrever o conjunto de dados de destino ou prever os resultados por meio do uso de algoritmos de aprendizado de máquina.

Esses métodos são usados para organizar e filtrar os dados, trazendo à tona as informações mais interessantes, desde a detecção de fraudes até o comportamento do usuário, gargalos e até falhas de segurança.

A mineração de dados em si é semelhante à ciência de dados quando realizada por uma pessoa, em uma situação específica, sobre um determinado conjunto de dados, com um objetivo. Esse processo inclui vários tipos de serviços, como mineração de texto, mineração da web, mineração de áudio e vídeo, mineração de dados de imagens e mineração de mídia social.

É de suma importância salientar um ponto: **dados incompletos e ruidosos**. Os dados no mundo real são heterogêneos, incompletos e ruidosos. Dados em grandes quantidades geralmente são imprecisos ou não confiáveis. Esses problemas podem ocorrer devido ao instrumento de medição de dados ou devido a erros humanos. A pessoa pode cometer um erro de digitação ao digitar o número de telefone, o que resulta em dados incorretos. Mesmo alguns clientes podem não estar dispostos a divulgar seus números de telefone, o que resulta em dados incompletos. Os dados podem ser alterados devido a erro humano ou do sistema. Todas essas consequências (dados ruidosos e incompletos) tornam a mineração de dados desafiadora. E esta é a vida real.

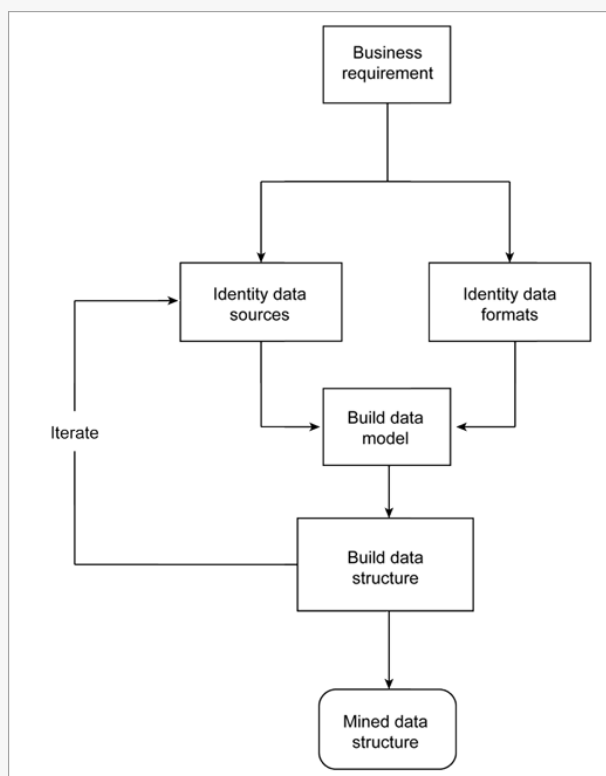
### 3.2. O processo de extração de dados

Qualquer problema de negócios examinará os dados brutos para criar um modelo que descreva as informações e apresente os relatórios a serem usados pelos negócios. Como vimos, construir um modelo a partir de fontes de dados e formatos de dados é um processo iterativo, pois os dados brutos estão disponíveis em muitas fontes e formatos diferentes.

Os dados estão aumentando dia a dia, portanto, quando uma nova fonte de dados é encontrada, ela pode alterar os resultados.

Abaixo está o esboço do processo, descrito na figura 9, pensando sempre do ponto de vista do negócio, que é o mais importante.

**Figura 9 – Data mining do ponto de vista do negócio.**



**Fonte: IBM.**

O que essa figura nos indica? Que o primeiro passo é o “*Business Requirement*”, ou seja, o que é importante para o negócio. Disto se parte para entender os dados e estruturá-los, *build data model*. Na sequência, define-se a estrutura na qual eles estarão organizados. Se tudo está de acordo com o negócio, inicia-se o trabalho de mineração (*mined data structure*). Se não, se reinicia o processo. Esse é um processo primariamente orientado a dados, mas que pode e deve ser expandido para uma versão mais ampla, que inclui o processo de modelagem matemática – o aprendizado de máquina. E esse é o ponto da próxima seção.

### 3.3. Modelos (técnicas) de Data Mining

A mineração de dados é mais útil na identificação de padrões de dados e na derivação de insights de negócios úteis a partir desses padrões. Para realizar essas tarefas, os mineradores de dados usam uma variedade de técnicas para gerar resultados diferentes. Aqui estão cinco técnicas comuns de mineração de dados.

- **Classificação:** com esta técnica, os pontos de dados são atribuídos a grupos ou classes com base em uma questão ou problema específico a ser resolvido. Por exemplo, se uma empresa de bens de consumo embalados deseja otimizar sua estratégia de cupom de desconto para um produto específico, ela pode revisar os níveis de estoque, dados de vendas, taxas de resgate de cupons e dados comportamentais do consumidor para tomar a melhor decisão possível.
- **Regras de associação:** esta função procura descobrir as relações entre os pontos de dados; é usado para determinar se uma ação ou variável específica tem alguma característica que possa ser vinculada a outras ações (por exemplo, escolhas de quartos e hábitos alimentares de viajantes a negócios). Um hoteleiro pode usar insights de regras de associação para oferecer upgrades de quarto ou promoções de alimentos e bebidas para atrair viajantes de negócios adicionais.
- **Deteção de Anomalia ou Outlier:** além de procurar padrões, a mineração de dados procura descobrir dados incomuns dentro de um conjunto. A deteção de anomalias é o processo de encontrar dados que não estão de acordo com o padrão. Esse processo pode ajudar a encontrar casos de fraude e ajudar os varejistas a saber mais sobre picos ou quedas nas vendas de determinados produtos.

- **Agrupamento:** procura semelhanças dentro de um conjunto de dados, separando pontos de dados que compartilham características comuns em subconjuntos. Isso é semelhante ao tipo de análise de classificação, pois agrupa pontos de dados, mas, na análise de agrupamento, os dados não são atribuídos a grupos previamente definidos. O agrupamento é útil para definir características em um conjunto de dados, como a segmentação de clientes com base no comportamento de compra, estado de necessidade, estágio de vida ou preferências prováveis em comunicação de marketing.
- **Regressão:** a análise de regressão trata da compreensão de quais fatores dentro de um conjunto de dados são mais importantes, quais podem ser ignorados e como esses fatores interagem.

### 3.4. Etapas de Data Mining

Existem muitos fatores que determinam a utilidade dos dados, como precisão, integridade, consistência e pontualidade. Os dados têm qualidade de satisfizerem a finalidade pretendida. Assim, o pré-processamento é crucial no processo de mineração de dados. Lembremos da figura 8 e o processo de descoberta de conhecimento com dados. A seguir falaremos sobre cada uma das etapas que você precisa saber.

#### Limpeza de dados

A limpeza de dados é o primeiro passo. É importante porque dados sujos, se usados diretamente na mineração, podem causar confusão nos procedimentos e produzir resultados imprecisos. Basicamente, essa etapa envolve a remoção de dados ruidosos ou incompletos da coleção. Muitos métodos que geralmente limpam os dados por si só estão disponíveis, mas não são robustos. Essa etapa realiza o trabalho de limpeza de rotina:

- **Preencha os dados faltantes:** dados faltantes podem ser preenchidos por métodos como:

- Ignorando a tupla.
  - Preenchendo o valor ausente manualmente.
  - Use a medida de tendência central ou mediana.
  - Preenchendo o valor mais provável.
- Remova os dados ruidosos: O erro aleatório é chamado de dados ruidosos. Os métodos para remover o ruído são:
  - Categorização: os métodos de categorização são aplicados classificando os valores em compartimentos ou categorias. A suavização é realizada consultando os valores vizinhos.
  - O binning é feito por suavização por bin, ou seja, cada bin é substituído pela média do bin. Suavização por uma mediana, onde cada valor de bin é substituído por uma mediana de bin. Suavização por limites de bin, ou seja, os valores mínimo e máximo no bin são limites de bin e cada valor de bin é substituído pelo valor de limite mais próximo.
    - Identificando os valores discrepantes;
    - Resolvendo inconsistências.

### Integração de dados

Quando várias fontes de dados heterogêneas, como bancos de dados, cubos de dados ou arquivos, são combinadas para análise, esse processo é chamado de integração de dados. Isso pode ajudar a melhorar a precisão e a velocidade do processo de mineração de dados. Diferentes bancos de dados têm diferentes convenções de nomenclatura de variáveis, causando redundâncias nos bancos de dados. A limpeza de dados adicional pode ser executada para remover as redundâncias e inconsistências da integração de dados sem afetar a confiabilidade dos dados.



A integração de dados pode ser realizada usando ferramentas de migração de dados, como Oracle Data Service Integrator e Microsoft SQL etc.

#### Redução de dimensionalidade

Essa técnica é aplicada para obter dados relevantes para análise a partir da coleta de dados. O tamanho da representação é muito menor em volume, mantendo a integridade. É realizada usando métodos como Naive Bayes, Árvores de Decisão, Rede Neural etc. Algumas estratégias de redução são:

- Redução de Dimensionalidade: Redução do número de atributos no conjunto de dados.
- Redução de Numerosidade: Substituição do volume de dados original por formas menores de representação de dados.
- Compactação de dados: representação compactada dos dados originais.

#### Transformação de dados

Nesse processo, os dados são transformados em um formato adequado para o processo de mineração de dados. Os dados são consolidados para que o processo de mineração seja mais eficiente e os padrões sejam mais fáceis de entender. A transformação de dados envolve mapeamento de dados e processo de geração de código. As estratégias para transformação de dados são:

- Suavização: remoção de ruído dos dados usando agrupamento, técnicas de regressão etc.
- Agregação: as operações de resumo são aplicadas aos dados.

- Normalização: dimensionamento de dados para cair dentro de um intervalo menor.
- Discretização: Valores brutos de dados numéricos são substituídos por intervalos. Por exemplo, Idade.

### Mineração de dados

Data Mining é um processo para identificar padrões interessantes e conhecimento a partir de uma grande quantidade de dados. Nessas etapas, padrões inteligentes são aplicados para extrair os padrões de dados. Os dados são representados na forma de padrões e os modelos são estruturados usando técnicas de classificação e agrupamento.

### Avaliação de padrões

Essa etapa envolve a identificação de padrões interessantes que representam o conhecimento com base em medidas de interesse. Métodos de resumo e visualização de dados são usados para tornar os dados compreensíveis pelo usuário.

### Visualização de dados e relatórios

A representação do conhecimento é uma etapa em que a visualização de dados e as ferramentas de representação do conhecimento são usadas para representar os dados minerados. Os dados são visualizados na forma de relatórios, tabelas etc.



**XP**e

## > Capítulo 4



## Capítulo 4. Compreensão e definição do alvo de modelos de renda variável

---

### 4.1. Definição do alvo e sua importância

Já aprendemos anteriormente que um modelo é uma representação matemática da realidade. Se tal realidade não for bem representada, definida, o modelo irá aprender algo, mas esse algo não a representará corretamente. Por isso, tão importante quanto as demais etapas, a definição do alvo, *target*, *label*, variável dependente, variável preditora, objetivo do modelo – todos sinônimos – é de fundamental importância. Até porque as variáveis que serão criadas devem estar alinhadas com o alvo. Ou seja, o alvo é a variável cujos valores são modelados e previstos por outras variáveis. Uma variável preditora é uma variável cujos valores serão usados para prever o valor da variável de destino.

O primeiro passo é entender o que se quer modelar. Pode ser a variação de um dia para o outro, de uma semana para outra, de 10 dias, de 20 dias, qualquer coisa. A escolha estará alinhada com os objetivos do negócio. Os exemplos e estudos neste curso estarão alinhados com a ideia de se o ativo irá subir ou cair em um período posterior, bem como teremos estudos em previsão de volatilidade.

Que tipo de variável de destino é usado para um algoritmo de regressão? No caso de modelos de regressão, o alvo é valor real, ou seja, o valor é em números reais. Em comparação com um modelo de classificação, o destino é binário ou multivalorado. Ou seja, na regressão, o objetivo é prever uma medição contínua para uma observação. Isto é, as variáveis de respostas são números reais. As aplicações incluem previsão de preços de ações, consumo de energia ou incidência de doenças.

Já para a classificação, o objetivo é atribuir uma classe (ou rótulo) de um conjunto finito de classes a uma observação. Melhor dizendo, as respostas são variáveis categóricas. Os aplicativos incluem filtros de spam, sistemas de recomendação de anúncios e reconhecimento de imagem e fala. Prever se um paciente terá um ataque cardíaco dentro de um ano é um problema de classificação, e as classes possíveis são verdadeiras e falsas. Os algoritmos de classificação geralmente se aplicam a valores de resposta ditos binários ou dicotômicos.

E o que é uma variável binária em estatística? Uma variável binária em estatística é uma variável com apenas dois valores. No nosso caso é: sobe ou desce.

No caso que temos o nosso alvo, temos o que chamamos de aprendizado de máquina supervisionado. O objetivo do aprendizado de máquina supervisionado é construir um modelo que faça previsões com base em evidências na presença de incerteza. Como os algoritmos adaptativos identificam padrões nos dados, um computador "aprende" com as observações. Quando exposto a mais observações, o computador melhora seu desempenho preditivo. Especificamente, um algoritmo de aprendizado supervisionado pega um conjunto conhecido de dados de entrada e respostas conhecidas aos dados (saída) e treina um modelo para gerar previsões razoáveis para a resposta a novos dados.

Além do alvo, é importante estar afiado para outras terminologias importantes do aprendizado de máquina. Aqui estão:

- **Variáveis, atributos ou *features*:** São variáveis independentes individuais que atuam como entrada em seu sistema. Os modelos de previsão usam as variáveis para fazer previsões. Novas variáveis também podem ser obtidas de outras variáveis usando um método conhecido como "*feature engineering*". Mais simplesmente, você

pode considerar uma coluna do seu conjunto de dados como uma variável. Às vezes, eles também são chamados de atributos.

- **Overfitting:** Uma consideração importante no aprendizado de máquina é quão bem a aproximação do modelo que foi treinado, usando dados de treinamento, generaliza para novos dados. A generalização funciona melhor se o sinal ou a amostra usada como dados de treinamento tiver uma alta relação sinal/ruído. Se não for esse o caso, a generalização seria ruim e não obteríamos boas previsões. Um modelo é super-ajustado (*overfitting*) se ajusta muito bem os dados de treinamento e há uma generalização ruim de novos dados. O contrário, *underfitting*, também é verdadeiro.
- **Regularização:** A regularização é o método para estimar uma complexidade preferencial do modelo de aprendizado de máquina para que o modelo generalize e o problema de super-ajuste/sub-ajuste seja evitado. Isso é feito adicionando uma penalidade nos diferentes parâmetros do modelo, reduzindo assim a liberdade do modelo.
- **Parâmetro e hiperparâmetro:** Parâmetros são variáveis de configuração que podem ser consideradas internas ao modelo, pois podem ser estimadas a partir dos dados de treinamento. Os algoritmos possuem mecanismos para otimizar parâmetros. Por outro lado, os hiperparâmetros não podem ser estimados a partir dos dados de treinamento. Os hiperparâmetros de um modelo são definidos e ajustados dependendo de uma combinação de algumas heurísticas e da experiência e conhecimento de domínio do cientista de dados.

#### 4.2. A importância da volatilidade para o alvo

A volatilidade é a alma do mercado. Essa frase tem que ficar sempre na cabeça de um cientista de dados que trabalha com o mercado financeiro.

É bem conhecido e de domínio público que a volatilidade é calculada usando variância e desvio padrão. Como a volatilidade mede a dispersão em um período específico, ela pode ser calculada com a fórmula da equação 2.

$$vol = \sigma\sqrt{T} \quad (2)$$

Onde:

- vol = volatilidade por um intervalo de tempo
- $\sigma$  = desvio padrão dos retornos
- T = número de períodos no horizonte de tempo

A princípio, para este curso, a volatilidade diária é calculada com uma janela móvel de 20 dias, pois representa uma proxy satisfatória para o número médio de dias de negociação em um mês útil. Multiplicar a volatilidade diária pela raiz quadrada de 252 dá a volatilidade anualizada. Se esse valor for dividido pela raiz quadrada de 12, é dado o valor da volatilidade mensal. Da mesma forma, se o valor da volatilidade anualizada for dividido pela raiz quadrada de 52, obtém-se a volatilidade semanal. Quando o valor da volatilidade dos retornos é então multiplicado por 100, dá o valor da dispersão em pontos percentuais (%).

E por que ela é importante para o alvo? Porque sempre devemos escolher ativos que tenham uma volatilidade mais elevada. Tudo o que esperamos de um ativo é que ele se mova para algum lugar, para que seja possível capturar melhor os movimentos com o modelo de aprendizado de máquina.

Dentro deste contexto, a volatilidade nem sempre é ruim, pois às vezes pode fornecer pontos de entrada dos quais os investidores podem tirar vantagem. A volatilidade descendente do mercado oferece aos investidores que acreditam que os mercados terão um bom desempenho no

longo prazo para comprar ações adicionais em empresas que eles gostam a preços mais baixos. O processo é o mesmo quando uma ação sobe rapidamente. Os investidores podem tirar proveito disso vendendo, cujos rendimentos podem ser investidos em outras áreas que representam maior oportunidade. Investir quando os mercados estão voláteis e as avaliações são mais atraentes pode dar aos investidores o potencial de gerar retornos fortes e de longo prazo.

#### 4.3. Métodos para a escolha do alvo

Em teoria, o processo CRISP-DM em sua etapa de “Entendimento do Negócio” é o momento no qual a escolha do alvo alinhada à necessidade do negócio é discutida. Entretanto, no caso da renda variável é necessário um pouco mais de técnica. Por exemplo, foi mencionado acima que um dos alvos possíveis é tentar prever se o ativo vai subir ou cair em um determinado período. Enquanto a definição de qual é o período advém para parte do entendimento do negócio, é possível refinar e trabalhar com mais precisão a ideia do “subir ou cair”. Como assim?

Sabemos que dos ativos do mercado financeiro, de um modo bastante aproximado, mas limitado às respectivas diferenças de volatilidade, possuem retornos distribuídos da seguinte maneira, de acordo com as figuras 10 e 11.

**Figura 10 – Descrição dos retornos do Ibovespa, 2012-2022.**

```
data[ "Returns" ].describe()
```

count	2690.000000
mean	0.000350
std	0.015699
min	-0.147797
25%	-0.008161
50%	0.000325
75%	0.009054
max	0.139082
Name: Returns, dtype: float64	

Fonte: O autor.



Figura 11 – Descrição dos retornos da PETR4, 2012-2022.

```
data[ "Returns" ].describe()  
  
count      2696.000000  
mean        0.000847  
std         0.030689  
min         -0.296978  
25%         -0.014852  
50%         0.000661  
75%         0.016129  
max         0.222222  
Name: Returns, dtype: float64
```

Fonte: O autor.

O que isso significa? Peguemos o exemplo do Ibovespa. A média é próxima à zero, e temos pelo 1º quartil que 25% dos dados são menores que -0.816% e que 25% são maiores que 0.905% (3º quartil). No caso da PETR4 esses valores seriam -1.48% e 1.61%, respectivamente. Portanto, como sabemos que um bom modelo é aquele que diferencia bem sinal do ruído, podemos fazer o nosso alvo sendo “sobe” apenas os dias que tivemos mais do que 0.905% de alta e “desce” quando menor do que -0.816% (no caso do Ibovespa). Isto potencializa a relação de retorno ruído. Para quaisquer outros valores, podemos ou não adicionar à base de treinamento do modelo ou adicionar com um label neutro, de “não fazer nada”. Afinal, ficar fora do mercado muitas vezes é uma ação muito legítima e aconselhada. Esta seção será mais bem aproveitada trabalhando de forma prática nas aulas de programação.

#### 4.4. Não é apenas sobre retornos

A ambição de ganhar dinheiro no mercado pode tornar o cientista de dados míope. Aprendemos que não se faz modelagem de preços e que uma alternativa são os retornos. Dado o fato que os mercados não são eficientes, esta ação é possível de ser explorada. Porém, o mercado não é apenas composto disto. Na seção 4.2 discutimos sobre a importância da volatilidade. A ideia é que ela não seja apenas um parâmetro de entrada para as variáveis e para a escolha do ativo, mas ela pode ser também o alvo em si

mesma. E, com a prática e como veremos mais adiante na seção 5.4, ela pode ser modelada mais facilmente do que os retornos. Também é possível – e comparativamente mais fácil do que os retornos – modelar eventos, tendências, zonas de preços (não confundir com modelar preços), dentre outros aspectos.

Tenha sempre clareza de que existem inúmeros meios de auferir ótimos resultados no mercado financeiro. Pense naquilo que os demais não estejam pensando e maximize o seu alpha.



**XP**e

# > Capítulo 5



## Capítulo 5. Algoritmos de aprendizado de máquina para trading

---

### 5.1. Long & Short por cointegração

Em uma primeira leitura, o aluno pode se perguntar o que uma seção sobre Long & Short por cointegração faria dentro de um capítulo sobre algoritmos de aprendizado de máquina. A resposta é simples e direta: ele é a aplicação mais direta e com ótimos resultados de uma regressão linear.

A cointegração é um método de trading dentro da categoria chamada de *Pairs Trading* (ou long e short) inventado na década de 1980 no banco de investimento Morgan Stanley.

Cointegração é uma forma de reversão à média que tem a vantagem distinta de estar majoritariamente (mas não sempre) protegida contra os movimentos do mercado. Geralmente é uma estratégia de alfa alto quando apoiada por algumas estatísticas rigorosas.

E como funciona? Dado um par de ativos X e Y que tenham algum vínculo econômico subjacente, se pudermos modelar esse vínculo econômico com um modelo matemático, podemos negociar com ele. E precisamos entender três conceitos matemáticos: estacionariedade e cointegração.

A estacionariedade, em matemática e estatística, é um processo estocástico cuja distribuição de probabilidade conjunta não muda à medida que é deslocado no tempo. Consequentemente, parâmetros como média e variância, se estiverem presentes, também não mudam com o tempo. Preços são não estacionários. Retornos tendem a ser estacionários.

Muitos testes estatísticos exigem que os dados testados sejam estacionários. O uso de determinadas estatísticas em um conjunto de dados não estacionário pode levar a resultados inúteis, não será útil para qualquer

previsão do estado futuro. Nos preços, as propriedades estatísticas, como média ou desvio padrão, não fazem sentido quando comparadas a qualquer momento específico, pois são um conjunto de diferentes estados em diferentes momentos misturados. Este é apenas um exemplo simples e claro de por que a não estacionariedade pode distorcer a análise.

Além disso, a correlação é uma medida da relação linear entre variáveis estacionárias. Como consequência, ao lidar com variáveis não estacionárias, a correlação é muitas vezes espúria. Por esse motivo, é uma boa prática evitar calcular coeficientes de correlação para fazer long e short.

Voltando aos nossos ativos X e Y, eles são cointegrados se for possível encontrar uma combinação linear  $Y - \beta X$  (lembra-se da fórmula da regressão linear) que seja integrada de ordem menor que d. No nosso caso, se os dois ativos são séries temporais não estacionárias de ordem 1 e se uma combinação linear entre dois títulos (spread) for testada para ser integrada de ordem 0, ou seja, estacionária, então definimos os dois ativos como cointegrados.

A cointegração, portanto, implica que as variáveis compartilham tendências estocásticas semelhantes e, então, seus resíduos seguem um processo estacionário. Duas variáveis cointegradas podem não necessariamente se mover na mesma direção (correlação), mas a distância entre elas permanecerá constante ao longo do tempo.

Para sermos precisos, devemos então realizar um teste estatístico para verificar se uma série é estacionária ou não. E isto facilmente é feito pelo Python com:

```
statsmodels.tsa.stattools import coint
```

Que, de acordo com a documentação, é um teste de não-cointegração de uma equação univariada. A hipótese nula é que não há cointegração pelo teste de cointegração de duas etapas de Engle-Granger

aumentado. A hipótese nula é que não há cointegração, a hipótese alternativa é que há relação de cointegração. Se o p-value for pequeno, abaixo de um tamanho crítico, podemos rejeitar a hipótese de que não há relação de cointegração.

## 5.2. Trading com Regressão Logística

Vimos em módulos anteriores os conceitos fundamentais de uma regressão logística. A direção do mercado é muito importante para investidores ou traders. Prever a direção do mercado é uma tarefa bastante desafiadora, pois os dados de mercado envolvem muito ruído. O mercado se move para cima ou para baixo e a natureza do movimento do mercado é binária. Um modelo de regressão logística nos ajuda a ajustar um modelo usando comportamento binário e previsão de direção do mercado, sendo um dos modelos probabilísticos que atribui probabilidade a cada evento.

Uma das formas de modelar uma regressão logística, neste caso, é considerar a tarefa de prever o movimento do preço das ações. Se o preço de fechamento de amanhã for maior do que o preço de fechamento de hoje, compraremos a ação (1), senão a venderemos (0). Se a saída for 0,7, podemos dizer que há 70% de chance de que o preço de fechamento de amanhã seja maior que o preço de fechamento de hoje e classificá-lo como 1. O inverso é verdadeiro para probabilidades perto de 0.

Para avaliar a performance do modelo, um dos meios mais utilizados e mais diretos é via matriz de confusão. Ela é usada para descrever o desempenho do modelo de classificação em um conjunto de conjuntos de dados de teste para os quais os valores verdadeiros são conhecidos. Na prática, é comum que os cientistas de dados refiram à performance de um classificador pelo percentual de acertos, que reflete a métrica chamada de acurácia; ou ainda pelo percentual de casos positivos que o modelo de fato acertou (que trata da métrica chamada de precisão). A acurácia é o percentual de acertos sobre todas as apostas do algoritmo. Porém, possui

diversas limitações, como por exemplo a possibilidade de enviesar o entendimento quando as classes da variável resposta não são balanceadas. Na tabela a seguir temos a representação da matriz de confusão.

	REAL POSITIVO = 1	REAL NEGATIVO = 0
PREDITO POSITIVO = 1	VP	FP
PREDITO NEGATIVO = 0	FN	VN

Sendo:

- Verdadeiro Positivo (VP): falou que subiria, e subiu.
- Verdadeiro Negativo (VN): falou que não subiria, e não subiu.
- Falso Positivo (FP): falou que subiria, mas não subiu.
- Falso Negativo (FN): falou que não subiria, mas subiu.

Com esses dados em mente, podemos calcular:

- **Taxa de Verdadeiro Positivo (TVP), Sensibilidade ou Recall:**  $TVP = VP / (FN + VP)$
- **Taxa de Falso Positivo (TFP, ou 1 – Especificidade):**  $TFP = FP / (VN + FP)$
- **Taxa de Verdadeiro Negativo (TVN) ou Especificidade:**  $TVN = VN / (VN + FP)$
- **Taxa de Falso Negativo (TFN):**  $TFN = FN / (FN + VP)$

- **Acurácia:**  $Acc = (VP+VN) / (VP+VN+FP+FN)$
- **Precisão:**  $Prec = VP / (VP+FP)$

Lembrando que essas métricas são utilizadas em qualquer tipo de modelo de classificação, assim como as redes neurais que serão vistas na próxima seção.

O objetivo desta apostila é fornecer os elementos conceituais, dado que a aula prática é o modo mais adequado de extrair o potencial e solidificar o aprendizado dessa técnica.

### 5.3. Trading com Rede Neural

O princípio de uso da rede neural como classificador binário é o mesmo da regressão logística. Porém, ela possui uma vantagem: poder lidar com alvos com mais de 2 classes mais facilmente (a logística também o faz, mas é melhor uma rede neural). Ainda na ideia de considerar a tarefa de prever o movimento do preço das ações, na rede neural podemos fazer:

- Se preço de fechamento de amanhã for maior do que o preço de fechamento de hoje por um determinado nível, compraremos a ação (1);
- Não faremos nenhum trading se o nível ficar entre um determinado intervalo do alvo;
- Senão a venderemos (-1) caso o preço de fechamento for menor que um determinado nível.

Repare que abrimos um universo de possibilidades. As redes neurais nos possibilitam também, estatisticamente, entender quando pode ser mais favorável ficar de fora do mercado. Isto é muito importante, pois reduz o risco e custo operacional de maneira significativa. E estes níveis serão decididos de acordo com a definição do alvo que víamos na seção 4.3.



#### 5.4. Previsão de volatilidade

A incerteza é inerente a qualquer modelo financeiro. É determinado pela mudança dos fundamentos, da psicologia humana e da maneira como os mercados respondem por possíveis estados futuros do ambiente macroeconômico. Embora a definição de incerteza nos mercados financeiros possa rapidamente degenerar em discussões filosóficas, a volatilidade é amplamente aceita como uma medida prática de risco. A maioria das variáveis de mercado permanece amplamente imprevisível, mas a volatilidade tem certas propriedades que podem aumentar a precisão de seus valores previstos. A natureza estatística da volatilidade é um dos principais catalisadores para a adoção de metas de volatilidade e estratégias de paridade de risco.

A previsão de volatilidade tem implicações importantes para todos os investidores que buscam retornos ajustados ao risco, particularmente aqueles que usam estratégias de alocação de ativos, paridade de risco e direcionamento de volatilidade. Compreender as diferentes abordagens para previsão de volatilidade e as implicações de suas suposições e interdependências fornece uma estrutura sólida para o orçamento de risco.

A volatilidade é a medida mais pura do risco nos mercados financeiros e, conseqüentemente, tornou-se o preço esperado da incerteza. O trade-off entre retorno e risco é fundamental para todas as decisões de investimento. Estimativas imprecisas de volatilidade podem deixar as instituições financeiras sem capital para operações e investimentos. Além disso, a volatilidade do mercado e seu impacto na confiança pública podem ter consequências significativas para a economia global em geral.

Aqui está a parte mais importante deste texto. É do conhecimento comum que a volatilidade é mais fácil de prever do que os retornos. Para a volatilidade, há uma série de fatos estilizados que a tornam inerentemente mais previsível. Portanto, prever a volatilidade é uma das metas mais

importantes e ao mesmo tempo mais alcançáveis para quem atribui risco e participa dos mercados financeiros.

A volatilidade dos retornos dos ativos é uma medida de quanto o retorno flutua em torno de sua média. Ela pode ser medida de várias maneiras, mas a mais simples é a volatilidade historicamente observada, que é medida como o desvio padrão dos retornos dos ativos em um determinado período.

Outra propriedade estilizada da volatilidade é que ela reverte para a média ao longo do tempo. A meia-vida da volatilidade é medida como o tempo que a volatilidade leva para se mover a meio caminho em direção à sua média de longo prazo.

Em um artigo publicado pelo autor - [Supply and Demand Levels Forecasting Based on Returns Volatility](#) – a volatilidade foi usada para, por exemplo, prever regiões de suporte e resistência. Os níveis de oferta e demanda, também chamados de resistência e suporte, são importantes impulsionadores das decisões de investimento e negociação em qualquer tipo de mercado. Para o comércio varejista no mercado de ações, a identificação dessas zonas é muito popular. No entanto, essas técnicas têm um problema: estão sujeitas à interpretação pessoal do cenário atual apontado por um gráfico ou indicadores calculados a partir de dados de preços passados. Este artigo propõe um método de identificação e previsão de zonas de oferta e demanda não definidas de forma arbitrária ou subjetiva em um gráfico, baseado no cálculo da volatilidade de cada ação/título, podendo ser generalizado para diferentes tipos de mercados.

Nas aulas práticas veremos um exemplo claro de previsão de volatilidade com aprendizado de máquina.



**XP**e

## > Capítulo 6



## Capítulo 6. Monitoramento e atualização de modelos de renda variável

---

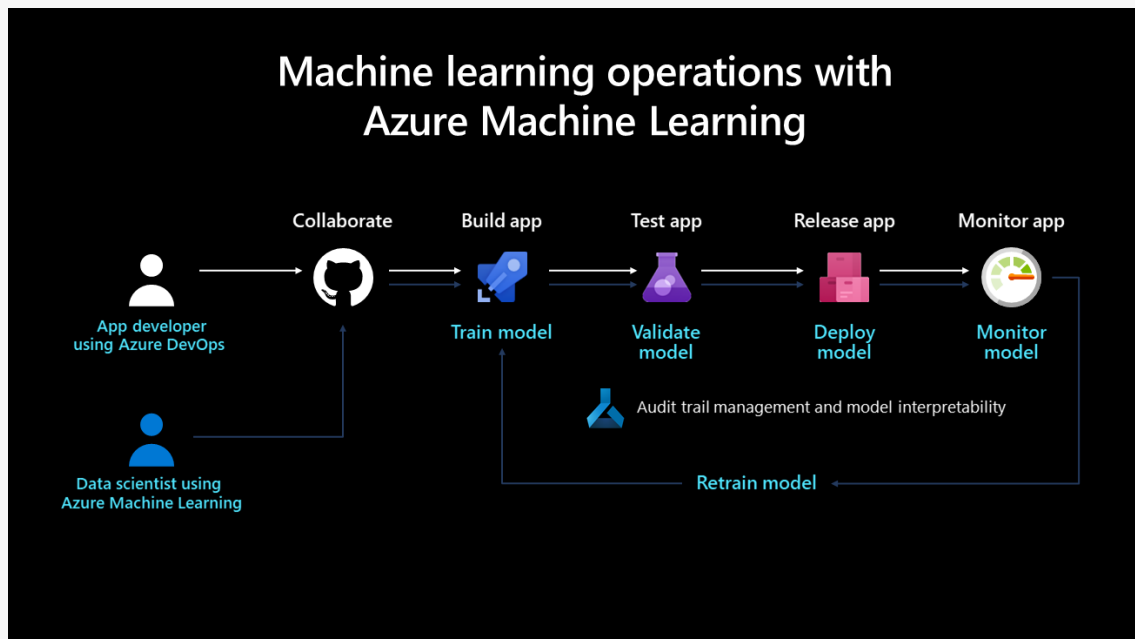
### 6.1. O que é monitoramento

O monitoramento do modelo é uma fase operacional no ciclo de vida do aprendizado de máquina que ocorre após a implantação dos modelos. Isso envolve monitorar seus modelos de ML em busca de alterações, como degradação do modelo, desvio de dados e desvio de conceito, e garantir que seu modelo mantenha um nível aceitável de desempenho.

Os modelos de aprendizado de máquina são frequentemente usados para automatizar decisões e processos críticos de negócios (por exemplo, previsão no mercado de ações, detecção de fraudes e aprovação de crédito). Esses modelos probabilísticos de aprendizado de máquina, ao contrário do software tradicional, podem mudar quando os dados de produção se desviam dos dados usados para treinar o modelo. Em outras palavras, o comportamento de um modelo é determinado pela imagem do mundo em que ele foi 'treinado' - mas os dados reais podem ser diferentes da imagem que ele 'aprendeu'. Por exemplo, se você ensinar um mouse a navegar perfeitamente por um labirinto, o mouse não funcionará tão bem em um novo labirinto que nunca viu.

Os modelos podem degradar por vários motivos: alterações em seus produtos ou políticas podem afetar o comportamento de seus clientes; atores adversários podem adaptar seu comportamento; pipelines de dados podem quebrar; e às vezes o mundo simplesmente evolui. Os motivos mais comuns para a degradação do modelo se enquadram nas categorias de desvio de dados e desvio de conceito. A figura 12 abaixo ilustra o processo de monitoramento, que pode ser generalizado para qualquer caso.

Figura 12 – Processo de monitoramento de um modelo.



Fonte: [MS Azure](#).

Essencialmente, o objetivo de monitorar seus modelos em produção é:

- Para detectar problemas com seu modelo e o sistema que atende seu modelo na produção antes que eles comecem a gerar valor comercial negativo;
- Para agir por modelos de triagem e solução de problemas em produção ou as entradas e sistemas que os permitem;
- Para garantir que suas previsões e resultados possam ser explicados e relatados;
- Para garantir que o processo de previsão do modelo seja transparente para as partes interessadas relevantes para uma governança adequada;
- Finalmente, fornecer um caminho para manter e melhorar o modelo em produção.

## 6.2. Quando substituir ou atualizar o modelo

A resposta para isso está condicionada à ocorrência de um ou mais dos casos que discutiremos a seguir. Como cientista de dados e com a ajuda de um engenheiro de machine learning (em grandes empresas), você é o principal responsável pelo monitoramento. Você está principalmente monitorando o desempenho do seu modelo em relação às entradas, bem como os resultados da previsão e o que acontece no modelo enquanto aprende na produção.

O primeiro ponto a se preocupar são os dados de entrada. O monitoramento funcional do nível de entrada é crucial na produção porque seu modelo reage às entradas que recebe. Se as entradas não forem o que seu modelo espera, isso provavelmente influenciará o desempenho.

Monitorar e medir os desafios de nível de entrada é o primeiro passo para solucionar problemas de desempenho funcional e resolvê-los antes que danos sérios sejam causados. Ele pode informá-lo com antecedência sobre a mudança do cenário e do contexto em torno do caso de negócios que você está resolvendo. Os modelos não são inteligentes o suficiente para se ajustar a um mundo em mudança, a menos que sejam constantemente treinados e atualizados.

Há um problema também com a distribuição dos dados de entrada. O desvio de dados (*data drift*) refere-se a uma mudança significativa na distribuição entre os dados de treinamento e os dados de produção. As alterações na distribuição dos dados de entrada afetarão o desempenho do modelo ao longo do tempo, embora seja um processo mais lento do que no caso de problemas de qualidade de dados.

Bem, após se preocupar com os dados, você tem que monitorar o modelo em si. E ele pode ter um desvio (*drift*) também, assim como os dados. O desvio de modelo, ou desvio de conceito, ocorre quando o relacionamento entre recursos e/ou rótulos – em casos de soluções de aprendizado

supervisionado ou não supervisionado – não é mais válido porque o relacionamento/padrões aprendidos mudaram com o tempo.

Um exemplo é a implementação de um modelo de classificação de sentimento. Com o tempo, o sentimento das pessoas sobre qualquer tópico muda. Se você treinou seu modelo em sentimentos positivos ou negativos com palavras e determinados tópicos, alguns sentimentos marcados como positivos podem, com o tempo, evoluir para negativos, você não pode descartar isso em nosso mundo de mídia social extremamente opinativo.

O desvio do modelo ocorre porque o mundo real muda (consequentemente, a verdade básica/alvo que o modelo foi treinado para prever) — as respostas às questões de negócios estão sempre evoluindo. O que vale hoje pode não valer mais amanhã, e espera-se que reflitamos esse fato em nossos aplicativos de aprendizado de máquina.

O desvio do modelo pode ser gradual, como quando o clima de negócios muda e evolui naturalmente, e pode ser repentino — como nos casos em que eventos extremos interrompem repentinamente todas as operações.

Por fim, mas não menos importante, você acompanha as saídas do modelo. Monitorar a saída do modelo na produção não é apenas o melhor indicador de desempenho do modelo, mas também nos informa se os KPIs de negócios estão sendo atendidos. Em termos de previsões do modelo, o mais importante a ser monitorado é o desempenho do modelo de acordo com as métricas de negócios.

O uso de métricas para avaliar o desempenho do modelo é uma grande parte do monitoramento do modelo em produção. Diferentes métricas podem ser usadas aqui, como classificação, regressão, agrupamento, aprendizado por reforço e assim por diante. Normalmente,

avaliamos o modelo usando métricas de pontuação de modelo predefinidas (exatidão, AUC, precisão etc.).

E qual métricas monitorar? Como visto anteriormente, as métricas para um modelo de classificação incluem:

- Matriz de confusão;
- ROC-AUC;
- Precisão e recall;
- F1-Score.

Já as métricas para um modelo de regressão incluem:

- Raiz do Erro Quadrático Médio (RMSE);
- R-quadrado e R-quadrado ajustado;
- Erro Absoluto Médio (MAE);
- Erro percentual médio absoluto (MAPE).

São essas os principais elementos de performance que você precisa monitorar.





**XP**e

# > Capítulo 7



## Capítulo 7. Seleção de carteira utilizando algoritmos de aprendizado de máquina

---

### 7.1. Seleção pelo método do K-means

Primeiramente precisamos aprender o que é o K-means. K-Means Clustering é um algoritmo de aprendizado não supervisionado, que agrupa o conjunto de dados não rotulado em diferentes clusters. Aqui K define o número de clusters pré-definidos que precisam ser criados no processo, pois se  $K=2$ , haverá dois clusters, e para  $K=3$ , serão três clusters, e assim por diante.

É usado principalmente em estatística e pode ser aplicado a quase qualquer ramo de estudo. Por exemplo, em marketing, pode ser usado para agrupar diferentes dados demográficos de pessoas em grupos simples que facilitam o direcionamento para os profissionais de marketing. Os astrônomos o usam para filtrar grandes quantidades de dados astronômicos; como eles não podem analisar cada objeto um por um, eles precisam encontrar estatisticamente pontos de interesse para observação e investigação.

No nosso caso, iremos utilizá-lo para selecionar ativos e compor uma carteira de investimentos em renda variável.


O algoritmo é relativamente simples:

- K pontos são colocados no espaço de dados do objeto representando o grupo inicial de centroides.
- Cada objeto ou ponto de dados é atribuído ao k mais próximo.
- Depois que todos os objetos são atribuídos, as posições dos k centroides são recalculadas.

- Os passos 2 e 3 são repetidos até que as posições dos centroides não se movam mais.

Podemos entendê-lo um pouco mais com o auxílio da figura 13.

Figura 13 – O K-means.



Fonte: [ai.plainenglish.io](http://ai.plainenglish.io).

Podemos ver claramente que nesse exemplo o K-means performa o agrupamento dos registros que estão mais próximos entre si, encontrando 5 clusters que é a quantidade ótima para ter a maior separação possível.

Em finanças quantitativas, o algoritmo k-means clustering será usado para agrupar as ações, dividir os diferentes tipos de pools de ações e revisar o cálculo dos retornos com base nas características (atributos ou variáveis) que construímos com os dados mercado, de modo a compor uma carteira que tenha um potencial de retorno. É preciso, por meio de experimentos com o número de clusters, obter o número ótimo de ações na carteira, como será visto na aula prática.

Este é um tema pouco explorado. Por isto na próxima seção temos uma lista recomendada de artigos para aprofundamento no assunto e instigar a curiosidade do aluno para que, potencialmente, uma nova linha de pesquisa seja percorrida.

## 7.2. Literatura relevante

Abaixo está a lista sugerida. Alguns tópicos são mais avançados, mas isto é natural em um novo campo de pesquisa como este.

- BABU, Suresh; GEETHANJALI, N.; SATYNARAYANA, B. Clustering Approach to Stock Market Prediction. In: **International Journal of Advanced Networking and Applications**. v. 3, ed. 4. jan./fev. 2012. p. 1281-1291. Disponível em: <<https://www.proquest.com/openview/cb0add4adccb4c5c203e59eb9fe48de7/1?pq-origsite=gscholar&cbl=886380>>. Acesso em: 24 jan. 2023.
- KUMARI, Sheshma kiran; et al. Mean-value at risk portfolio selection problem using clustering technique: a case study. In: **AIP Conference Proceeding**. v. 2112, n. 1. jun. 2019. p. 020178. Disponível em: <<https://aip.scitation.org/doi/pdf/10.1063/1.5112363>>. Acesso em: 24 jan. 2023.
- MOMENI, Mansoor; MOHSENI, Maryam; SOOFI, Mansour. Clustering stock market companies via k-means algorithm. In: **Kuwait Chapter of Arabian Journal of Business and Management Review**. v. 4, n. 5. jan. 2015. Disponível em: <[http://www.arabianjbmr.com/pdfs/KD\\_VOL\\_4\\_5/1.pdf](http://www.arabianjbmr.com/pdfs/KD_VOL_4_5/1.pdf)>. Acesso em: 24 jan. 2023.
- NANDA, S. R.; MAHANTY; Biswajit; TIWARI; Manoj Kumar. Clustering Indian Stock market data for portfolio management. In: **Expert Systems With Applications**. v. 37, n. 12. 30 nov. 2010. p. 8793-8798. Disponível em: <<https://www.scinapse.io/papers/2100826087>>. Acesso em: 24 jan. 2023.

- WU, Dingming; WANG, Xiaolong; WU, Shaocong. Construction of stock portfolios based on k-means clustering of continuous trend features. In: **Knowledge-Based Systems**. v. 252. 27 set. 2022. Disponível em: <<https://www.sciencedirect.com/science/article/abs/pii/S0950705122006815>>. Acesso em: 24 jan. 2023.



**XP**e

## > Capítulo 8



## Capítulo 8. Métodos quantitativos para gestão de risco

---

### 8.1. O que é o VaR

O Value at Risk – ou VaR – é uma medida estatística do risco de entidades financeiras ou carteiras de ativos. É definido como o valor máximo em unidades da moeda que é calculado em unidades percentuais que se espera perder em um determinado horizonte de tempo, em um nível de confiança predefinido. Por exemplo, se o VaR de um mês de 95% for R\$1 milhão, há 95% de confiança de que no próximo mês o portfólio não perderá mais de R\$1 milhão.

O VaR pode ser calculado usando diferentes técnicas. No método paramétrico, também conhecido como método de variância-covariância, o VaR é calculado em função da média e da variância das séries de retornos, assumindo distribuição normal. Com o método histórico, o VaR é determinado tomando os retornos pertencentes ao quintil mais baixo da série (identificado pelo nível de confiança) e observando o maior desses retornos. O método de Monte Carlo simula muitos cenários para o portfólio e determina o VAR observando a distribuição dos caminhos resultantes.

O Valor em Risco é comumente usado por:

- Bancos comerciais e de investimento;
- Fundos de hedge;
- Fundos mútuos;
- Corretores ou traders.

Os bancos de investimento aplicam a modelagem VaR em toda a empresa devido ao potencial de mesas de negociação independentes exporem a empresa a ativos altamente correlacionados, aumentando assim

o risco da empresa. Ou seja, o VaR é frequentemente utilizado por empresas que lidam com diversos investimentos arriscados como forma de monitorar e controlar o nível de risco total da empresa. O VaR é normalmente usado para avaliar a exposição ao risco de toda a empresa, em vez do risco específico do investimento. As empresas o empregam para prever o tamanho das perdas ou ganhos futuros que suas carteiras (ou de seus clientes) podem experimentar.

Muitas empresas também usam o VaR para determinar a quantidade de garantia necessária de um cliente para um empréstimo de margem ao negociar instrumentos financeiros. Entidades de compra, como fundos de hedge, usam VaR para determinar se a alocação de um portfólio excede uma tolerância de risco atual ou mandato de investimento.

## 8.2. O problema do VaR

O primeiro problema é que gera uma falsa sensação de segurança. Muitas pessoas pensam no VaR como "o máximo que posso perder", especialmente quando é calculado com o parâmetro de confiança definido em 99%. Mesmo quando você entende o verdadeiro significado do VaR em um nível consciente, subconscientemente a confiança de 99% pode embalá-lo em uma falsa sensação de segurança.

Infelizmente, na realidade 99% estão muito longe de 100% e é aqui que as limitações do VaR e sua compreensão incompleta podem ser fatais. Um VaR de 99% por cento realmente significa que em 1% dos casos (como 2-3 dias de negociação em um ano com VaR diário) a perda deve ser maior do que o valor do VaR. Ele não diz nada sobre o tamanho das perdas dentro desse 1% dos dias de negociação e de forma alguma diz nada sobre a perda máxima possível.

A perda do pior caso pode ser apenas alguns por cento maior do que o VaR, mas também pode ser alta o suficiente para liquidar sua empresa. Alguns desses "2-3 dias de negociação por ano" podem ser aqueles com



ataques terroristas, falência de grandes bancos e eventos extraordinários semelhantes de alto impacto. Você simplesmente não sabe sua perda máxima possível olhando apenas para o VaR. É a limitação mais importante e frequentemente ignorada do Valor em Risco.

Além dessa falsa sensação de problema de segurança, há outras (talvez discutidas com menos frequência, mas ainda válidas) limitações do Value At Risk e elas são matemáticas.

Os principais pressupostos matemáticos desse modelo são:

- Distribuição normal da distribuição de probabilidade;
- As mudanças nos valores do instrumento são lineares em relação às mudanças nos fatores de risco;
- A variação esperada no preço da variável de mercado ao longo do período é zero.

Como veremos na aula prática, nenhuma das premissas são válidas.

### 8.3. Conditional Value at Risk (CVaR)

O Conditional Value-at-Risk (CVaR), introduzido por Rockafellar e Uryasev (2000), é uma ferramenta popular para gerenciar riscos e endereça a resolução de alguns dos problemas do VaR. O CVaR aproximadamente (ou exatamente, sob certas condições) é igual à média de alguma porcentagem dos piores cenários de perda. A medida de risco CVaR é semelhante à medida do VaR, que é um percentil de uma distribuição de perda.

Existe uma estreita correspondência entre CVaR e VaR: com o mesmo nível de confiança, VaR é um limite inferior para CVaR. Se as caudas tiverem mais massa, isso irá ser capturado pelo CVaR. Em geral, é considerada uma métrica muito superior em comparação com o VaR e você deve usá-la sobre o VaR na maioria dos casos.

O CVaR é o que muitos consideram uma melhoria do VaR, pois leva em consideração a forma da distribuição dos retornos (lembre-se do que vimos anteriormente dos problemas matemáticos do VaR). Também é conhecido como Expected Shortfall (ES), pois é uma expectativa sobre todas as diferentes perdas possíveis maiores que o VaR e suas correspondentes probabilidades estimadas.

Não é demais estressar esse ponto. Os investimentos geralmente dependem do VaR porque ele não fica atolado em dados atípicos nos modelos – os outliers. No entanto, houve momentos em que produtos ou modelos técnicos teriam sido mais bem construídos e usados com mais prudência se o CVaR tivesse sido escolhido. A história está repleta de exemplos como o *Long-Term Capital Management*, que se baseou no VaR para medir seu perfil de risco e, no entanto, faliu ao não contabilizar adequadamente uma perda maior do que a prevista pelo modelo VaR. Nesse caso, o CVaR teria alinhado o fundo de hedge com o risco real, e não com o limite do VaR. Na modelagem financeira, quase sempre há um debate sobre VaR versus CVaR para uma gestão de risco eficiente.

Uma excelente referência para estudos posteriores (e mais avançados), está neste artigo:

- SARYKALIN, Sergey; SERRAINO, Gaia; URYASEV, Stan. Value-at-Risk vs. Conditional Value-at-Risk in Risk Management and Optimization. In: **Tutorials in Operations Research**. 2008. p. 270-294. Disponível em: [https://www.ise.ufl.edu/uryasev/files/2011/11/VaR\\_vs\\_CVaR\\_INFO\\_RMS.pdf](https://www.ise.ufl.edu/uryasev/files/2011/11/VaR_vs_CVaR_INFO_RMS.pdf). Acesso em: 24 jan. 2023.

Uma outra está aqui:

- FORGHIERI, Simone. Portfolio Optimization using CVaR. Department of Economics and Finance Mathematical Finance –

LUISS Guido Carli. 2013-14. Disponível em:  
<<https://tesi.luiss.it/12528/1/forghieri-simone-tesi-2014.pdf>>.

Acesso em: 24 jan. 2023.

#### 8.4. Critério de Kelly

John Kelly era um cientista do AT&T Bell Labs. Ele ouviu falar de jogadores profissionais e ficou curioso sobre como os jogadores administravam seu capital diante da incerteza. Curiosamente, ele não se importava com quanto dinheiro eles ganhavam, mas como eles configuravam o tamanho da aposta para obter o máximo de dinheiro. Assim como as histórias de jogos de azar mais bem-sucedidas, Kelly aplicou a matemática da teoria da informação para criar o Critério de Kelly (KC). Com o KC, um jogador poderia fazer o melhor tamanho de aposta para obter o máximo de dinheiro a longo prazo, se conhecesse suas chances de ganhar e perder.

Existem duas partes principais no Critério de Kelly (KC): probabilidade de vitória e proporção de vitórias/perdas, representados pela fórmula abaixo:

$$K\% = W - \frac{(1 - W)}{R}$$

Onde K% é o percentual de Kelly, W é a probabilidade de vitória e R é a taxa de Acertos/Perdas (monetário). Mas o KC tem mais aplicações do que apenas jogos de azar. Pode aplicar-se a qualquer decisão em que conhecemos os valores das variáveis – incluindo aqui os nossos modelos quantitativos. Os investidores e traders mais experientes aprenderam que se deve apostar alto quando o mundo lhes oferece essa oportunidade. Eles apostam alto quando têm chances. E o resto do tempo, eles não. É simples assim, parafraseando Charlie Munger.

Simplificando a história para o mercado de ações, o critério de Kelly aplicado ao mercado de ações é:

Fração de capital que deve ser alocada = Edge / Odds

Onde o Edge é calculado pelo valor total esperado (a esperança matemática), obtido pela soma da multiplicação do resultado possível de cada cenário por sua probabilidade correspondente. As probabilidades (Odds) são diretamente o resultado positivo que pode ser obtido e são a saída do modelo quantitativo, dado que a probabilidade mede o quão certo um determinado evento acontecerá em uma instância específica. O Valor Esperado representa o resultado médio de uma série de eventos aleatórios com probabilidades idênticas repetidas durante um longo período.

Apesar de apresentar uma ideia inovadora (mesmo que seja antiga), sempre temos que saber dos riscos. Você não precisa seguir fórmula de Kelly pelo livro. Use-o como um indicador de quão boas são as probabilidades e aplique um percentual do tamanho recomendado, para fins especulativos.

Afinal, a recomendação vinda do KC depende muito da precisão para determinar probabilidades e resultados, dados não são facilmente obtidos, pois você precisa calcular a estimativa de valor intrínseco para determinar alfa.

## Referências

---

BERRY, M. J.; LINOFF, G. S. **Data mining techniques**: for marketing, sales, and customer relationship management. John Wiley & Sons. 2004.

DASE, R. K.; PAWAR, D. D. Application of Artificial Neural Network for stock market predictions: A review of literature. In: **International Journal of Machine Intelligence**, v. 2, n. 2. 2010. p. 14-17.

GUJARATI, D. N. **Econometrics by example**. v. 1. New York: Palgrave Macmillan, 2011.

HASTIE, Trevor; TIBSH, Robert; FRIEDMAN, Jerome. **The Elements of Statistical Learning**: Data Mining, Inference, and Prediction, Second Edition. v. 2. Nova Iorque: Springer, 2009. p. 1 fev. 2009.

JOBSON, J. D.; KORKIE, B. Estimation for Markowitz efficient portfolios. In: **Journal of the American Statistical Association**, v. 75, n. 371. 1980. p. 544-554.

PINTO, Jerald E.; HENRY, Elaine; ROBINSON, Thomas R.; STOWE, John D. **Equity Asset Valuation**. 2. ed. John Wiley & Sons, 8 fev. 2010.

YOO, P. D.; KIM, M. H.; JAN, T. Machine learning techniques and use of event information for stock market prediction: A survey and evaluation. In: **International Conference on Computational Intelligence for Modelling, Control and Automation and International Conference on Intelligent Agents, Web Technologies and Internet Commerce (CIMCA-IAWTIC'06)**. v. 2. nov. 2005. p. 835-841.